

# ECONOMETRÍA

## TEMA 3: EL MODELO LINEAL (II)

2024-2025

# EL MODELO LINEAL (II)

<b>1</b>	<b>Propiedades estadísticas del estimador . . . . .</b>	<b>2</b>
1.1	Valor Esperado y Varianza de los EMCO . . . . .	2
1.2	Teorema de Gauss-Markov . . . . .	4
1.3	Estimación de $\sigma_u^2$ . . . . .	9
1.4	Estimación de la varianza de los EMCO . . . . .	11
<b>2</b>	<b>El supuesto de normalidad y la inferencia sobre los parámetros del modelo . . . . .</b>	<b>12</b>
2.1	Intervalos de confianza para los parámetros del modelo . . . . .	13
2.2	Contraste de hipótesis acerca de los parámetros del modelo. Test General .	14
2.2.1	Casos particulares . . . . .	17
<b>3</b>	<b>Predicción . . . . .</b>	<b>26</b>

## 1.1. VALOR ESPERADO Y VARIANZA DE LOS EMCO

El estimador EMCO de  $\vec{\beta}$  del modelo  $\vec{y} = X\vec{\beta} + \vec{u}$  es:

$$\vec{\hat{\beta}} = (X^t X)^{-1} (X^t \vec{y})$$

## 1.1. VALOR ESPERADO Y VARIANZA DE LOS EMCO

El estimador EMCO de  $\vec{\beta}$  del modelo  $\vec{y} = X\vec{\beta} + \vec{u}$  es:

$$\vec{\hat{\beta}} = (X^t X)^{-1} (X^t \vec{y})$$

Sustituyendo  $\vec{y}$  por  $\vec{y} = X\vec{\beta} + \vec{u}$ :

$$\begin{aligned}\vec{\hat{\beta}} &= (X^t X)^{-1} (X^t \vec{y}) = (X^t X)^{-1} X^t (X\vec{\beta} + \vec{u}) \\ &= \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.\end{aligned}$$

## 1.1. VALOR ESPERADO Y VARIANZA DE LOS EMCO

El estimador EMCO de  $\vec{\beta}$  del modelo  $\vec{y} = X\vec{\beta} + \vec{u}$  es:

$$\vec{\hat{\beta}} = (X^t X)^{-1} (X^t \vec{y})$$

Sustituyendo  $\vec{y}$  por  $\vec{y} = X\vec{\beta} + \vec{u}$ :

$$\begin{aligned}\vec{\hat{\beta}} &= (X^t X)^{-1} (X^t \vec{y}) = (X^t X)^{-1} X^t (X\vec{\beta} + \vec{u}) \\ &= \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.\end{aligned}$$

Por tanto,

$$\vec{\hat{\beta}} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.$$

## 1.1. VALOR ESPERADO Y VARIANZA DE LOS EMCO

El estimador EMCO de  $\vec{\beta}$  del modelo  $\vec{y} = X\vec{\beta} + \vec{u}$  es:

$$\vec{\hat{\beta}} = (X^t X)^{-1} (X^t \vec{y})$$

Sustituyendo  $\vec{y}$  por  $\vec{y} = X\vec{\beta} + \vec{u}$ :

$$\begin{aligned}\vec{\hat{\beta}} &= (X^t X)^{-1} (X^t \vec{y}) = (X^t X)^{-1} X^t (X\vec{\beta} + \vec{u}) \\ &= \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.\end{aligned}$$

Por tanto,

$$\vec{\hat{\beta}} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.$$

$$E \left[ \vec{\hat{\beta}} \right] = E \left[ \vec{\beta} + (X^t X)^{-1} (X^t \vec{u}) \right] = \vec{\beta} + (X^t X)^{-1} X^t E[\vec{u}] = \vec{\beta}$$

ya que  $E[\vec{u}] = \vec{0} \Rightarrow \vec{\hat{\beta}}$  es un estimador **insesgado** de  $\vec{\beta}$ .

## 1.1. VALOR ESPERADO Y VARIANZA DE LOS EMCO

$$\begin{aligned}\text{var}\left(\vec{\beta}\right) &= E\left[\left(\vec{\beta} - E\left[\vec{\beta}\right]\right) \cdot \left(\vec{\beta} - E\left[\vec{\beta}\right]\right)^t\right] = \\ &= E\left[\left(\vec{\beta} - \vec{\beta}\right) \cdot \left(\vec{\beta} - \vec{\beta}\right)^t\right] = \\ &= E\left[\left(X^t X\right)^{-1} \left(X^t \vec{u}\right) \cdot \left(\vec{u}^t X\right) \left(X^t X\right)^{-1}\right] = \\ &= \left(X^t X\right)^{-1} X^t \cdot E\left[\vec{u} \cdot \vec{u}^t\right] \cdot X \left(X^t X\right)^{-1} = \\ &= \sigma^2 \cdot \left(X^t X\right)^{-1} X^t X \left(X^t X\right)^{-1} = \sigma^2 \cdot \left(X^t X\right)^{-1},\end{aligned}$$

## 1.2. TEOREMA DE GAUSS-MARKOV

[Gauss–Markov] Los estimadores mínimos cuadrados ordinarios de  $\vec{\beta}$  son BLUE (ELIO en español):

- ▶ óptimos, (Best)
- ▶ lineales, (Linear) y
- ▶ insesgados (Umbiased)

Según el Teorema de Gauss-Markov podemos decir que entre todos los estimadores lineales e insesgados de  $\vec{\beta}$ , el EMCO es el que presenta menor matriz de varianzas-covarianzas.



## 1.2. TEOREMA DE GAUSS-MARKOV: DEMO (I)

- $\vec{\beta}$  es lineal con respecto al vector  $\vec{y}$ .

Definiendo la matriz de dimensión  $k \times n$  como  $W = (X^t X)^{-1} X^t$  es fácil comprobar que  $\vec{\beta}$  es un estimador lineal con respecto a las observaciones  $\vec{y}$ , ya que

$$\vec{\beta} = (X^t X)^{-1} (X^t \vec{y}) = W \vec{y}$$

## 1.2. TEOREMA DE GAUSS-MARKOV: DEMO (I)

- $\vec{\beta}$  es lineal con respecto al vector  $\vec{y}$ .

Definiendo la matriz de dimensión  $k \times n$  como  $W = (X^t X)^{-1} X^t$  es fácil comprobar que  $\vec{\beta}$  es un estimador lineal con respecto a las observaciones  $\vec{y}$ , ya que

$$\vec{\beta} = (X^t X)^{-1} (X^t \vec{y}) = W \vec{y}$$

- $\vec{\beta}$  es un estimador insesgado de  $\vec{\beta}$ .

Si  $\vec{\beta}$  es un estimador insesgado de  $\vec{\beta}$  entonces es porque se verifica que  $E \left[ \vec{\beta} \right] = \vec{\beta}$  (ya lo sabemos).

## 1.2. TEOREMA DE GAUSS-MARKOV: DEMO (II)

- $\vec{\beta}$  es un estimador óptimo de  $\vec{\beta}$ .

Consideremos otro estimador lineal e insesgado, alternativo a  $\vec{\beta}: \vec{\beta}^*$ .

- Como  $\vec{\beta}^*$  es lineal en  $\vec{y}$  entonces se verifica que existe  $C_{k \times n}$  tal que  $\vec{\beta}^* = C\vec{y}$ .

- Al verificarse que  $\vec{\beta}^*$  es un estimador insesgado de  $\vec{\beta}$  entonces  $E[\vec{\beta}^*] = \vec{\beta}$ . Luego:

$$\begin{aligned} E[\vec{\beta}^*] &= E[C\vec{y}] = E\left[C\left(X\vec{\beta} + \vec{u}\right)\right] = E\left[ CX\vec{\beta} \right] + \\ &\quad + E\left[ C\vec{u} \right] = CE\left[ X\vec{\beta} \right] + CE\left[ \vec{u} \right] = CX\vec{\beta} \end{aligned}$$

Así que para que  $\vec{\beta}^*$  sea insesgado se debe verificar:  $CX = I_k$ .

## 1.2. TEOREMA DE GAUSS–MARKOV: DEMO (III)

$$\begin{aligned}\text{var} \left( \vec{\widetilde{\beta}}^* \right) &= E \left[ \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right) \cdot \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right)^t \right] = \\ &= E \left[ \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right) \cdot \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right)^t \right] = E \left[ C \vec{u} \cdot \vec{u}^t C^t \right] = \\ &= CE \left[ \vec{u} \cdot \vec{u}^t \right] C^t = C \sigma^2 I_n C^t = \sigma^2 C C^t\end{aligned}$$

## 1.2. TEOREMA DE GAUSS–MARKOV: DEMO (III)

$$\begin{aligned}\text{var} \left( \vec{\widetilde{\beta}}^* \right) &= E \left[ \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right) \cdot \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right)^t \right] = \\ &= E \left[ \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right) \cdot \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right)^t \right] = E \left[ C \vec{u} \cdot \vec{u}^t C^t \right] = \\ &= CE \left[ \vec{u} \cdot \vec{u}^t \right] C^t = C \sigma^2 I_n C^t = \sigma^2 C C^t\end{aligned}$$

Tenemos que  $\vec{\widetilde{\beta}} = W \vec{y}$  y que  $\vec{\widetilde{\beta}}^* = C \vec{y}$ .

Si denotamos por  $D = C - W$ :

$$DX = (C - W) X = CX - WX = CX - (X^t X)^{-1} X^t X = I_k - I_k = 0_k$$

## 1.2. TEOREMA DE GAUSS–MARKOV: DEMO (III)

$$\begin{aligned}\text{var} \left( \vec{\widetilde{\beta}}^* \right) &= E \left[ \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right) \cdot \left( \vec{\widetilde{\beta}}^* - E \left[ \vec{\widetilde{\beta}}^* \right] \right)^t \right] = \\ &= E \left[ \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right) \cdot \left( \vec{\widetilde{\beta}}^* - \vec{\beta} \right)^t \right] = E \left[ C \vec{u} \cdot \vec{u}^t C^t \right] = \\ &= CE \left[ \vec{u} \cdot \vec{u}^t \right] C^t = C \sigma^2 I_n C^t = \sigma^2 C C^t\end{aligned}$$

Tenemos que  $\vec{\widetilde{\beta}} = W \vec{y}$  y que  $\vec{\widetilde{\beta}}^* = C \vec{y}$ .

Si denotamos por  $D = C - W$ :

$$DX = (C - W) X = CX - WX = CX - (X^t X)^{-1} X^t X = I_k - I_k = 0_k$$

$$\Rightarrow \text{var} \left( \vec{\widetilde{\beta}}^* \right) = \sigma^2 C C^t = \sigma^2 (W + D) (W + D)^t = \sigma^2 (W W^t + W D^t + D W^t + D D^t)$$

## 1.2. TEOREMA DE GAUSS–MARKOV: DEMO (IV)

$$WW^t = \left( (X^t X)^{-1} X^t \right) \left( (X^t X)^{-1} X^t \right)^t = (X^t X)^{-1},$$

$$WD^t = \left( (X^t X)^{-1} X^t \right) D^t = 0_{k \times k},$$

$$DW^t = D \left( (X^t X)^{-1} X^t \right)^t = 0_{k \times k},$$

## 1.2. TEOREMA DE GAUSS–MARKOV: DEMO (IV)

$$WW^t = \left( (X^t X)^{-1} X^t \right) \left( (X^t X)^{-1} X^t \right)^t = (X^t X)^{-1},$$

$$WD^t = \left( (X^t X)^{-1} X^t \right) D^t = 0_{k \times k},$$

$$DW^t = D \left( (X^t X)^{-1} X^t \right)^t = 0_{k \times k},$$

$$\begin{aligned} \text{var} \left( \vec{\widetilde{\beta}}^* \right) &= \sigma^2 (WW^t + WD^t + DW^t + DD^t) = \\ &= \sigma^2 WW^t + \sigma^2 DD^t = \sigma^2 (X^t X)^{-1} + \sigma^2 DD^t = \\ &= \text{var} \left( \vec{\widetilde{\beta}} \right) + \sigma^2 DD^t \end{aligned}$$

$$\text{var} \left( \vec{\widetilde{\beta}}^* \right) - \text{var} \left( \vec{\widetilde{\beta}} \right) = \sigma^2 DD^t \succcurlyeq 0 \Rightarrow \text{var} \left( \vec{\widetilde{\beta}}^* \right) \succcurlyeq \text{var} \left( \vec{\widetilde{\beta}} \right).$$



## 1.3. ESTIMACIÓN DE $\sigma_u^2$

El vector de residuos es:

$$\begin{aligned}\vec{e} &= \vec{y} - \vec{\hat{y}} = \vec{y} - X \vec{\hat{\beta}} = \vec{y} - X \left( (X^t X)^{-1} (X^t \vec{y}) \right) = \\ &= \left( I_n - X (X^t X)^{-1} X^t \right) \vec{y} = M_X \vec{y}\end{aligned}$$

donde  $M_X = I_n - X (X^t X)^{-1} X^t$  es la matriz complemento del proyector ortogonal.

La matriz  $M_X$  verifica:

- ▶  $M_X^t = M_X$  (simétrica)
- ▶  $M_X^2 = M_X$  (idempotente)
- ▶  $\text{traza}(M_X) = n - k$ .
- ▶  $M_X X = \left( I_n - X (X^t X)^{-1} X^t \right) X = X - X = 0_{n \times k}$ .

## 1.3. ESTIMACIÓN DE $\sigma_u^2$

Como  $\vec{y} = X\vec{\beta} + \vec{u}$ :

$$\vec{e} = M_X \vec{y} = M_X (X\vec{\beta} + \vec{u}) = M_X X\vec{\beta} + M_X \vec{u} = M_X \vec{u}$$

Tomando valores esperados se tiene:

$$\begin{aligned} E [\vec{e}^t \vec{e}] &= E [(M_X \vec{u})^t M_X \vec{u}] &&= E [\vec{u}^t M_X \vec{u}] \\ &= E [\text{traza} (\vec{u}^t M_X \vec{u})] &&= \text{traza} (M_X E [\vec{u} \vec{u}^t]) \\ &= \text{traza} (M_X \sigma^2 I_n) &&= \sigma^2 \text{traza} (M_X) = \sigma^2 (n - k) \end{aligned}$$

(Nota:  $\vec{u}^t M_X \vec{u}$  es un escalar.)

## 1.3. ESTIMACIÓN DE $\sigma_u^2$

Como  $\vec{y} = X\vec{\beta} + \vec{u}$ :

$$\vec{e} = M_X \vec{y} = M_X (X\vec{\beta} + \vec{u}) = M_X X\vec{\beta} + M_X \vec{u} = M_X \vec{u}$$

Tomando valores esperados se tiene:

$$\begin{aligned} E [\vec{e}^t \vec{e}] &= E [(M_X \vec{u})^t M_X \vec{u}] &&= E [\vec{u}^t M_X \vec{u}] \\ &= E [\text{traza} (\vec{u}^t M_X \vec{u})] &&= \text{traza} (M_X E [\vec{u} \vec{u}^t]) \\ &= \text{traza} (M_X \sigma^2 I_n) &&= \sigma^2 \text{traza} (M_X) = \sigma^2 (n - k) \end{aligned}$$

(Nota:  $\vec{u}^t M_X \vec{u}$  es un escalar.)

Como  $E \left[ \frac{\vec{e}^t \vec{e}}{n - k} \right] = \sigma^2$ , se concluye que un estimador insesgado de la varianza de las perturbaciones,  $\sigma_u^2$ , será:

$$\hat{\sigma}_u^2 = \frac{\vec{e}^t \vec{e}}{n - k} = \frac{SCR}{n - k}$$

## 1.4. ESTIMACIÓN DE LA VARIANZA DE LOS EMCO

La varianza del EMCO  $\vec{\beta}$  era:

$$\text{var} \left( \vec{\beta} \right) = \sigma^2 \cdot (X^t X)^{-1},$$

Como dicha expresión depende de la varianza de la perturbación, **no se puede determinar**. Teniendo en cuenta que el estimador insesgado de la varianza del término de perturbación es

$$\hat{\sigma}^2 = \frac{\vec{e}^t \vec{e}}{n - k} = \frac{SCR}{n - k},$$

se obtiene que la estimación de la matriz de varianzas-covarianzas de  $\vec{\beta}$  es:

$$\widehat{\text{var}} \left( \vec{\beta} \right) = \frac{SCR}{n - k} \cdot (X^t X)^{-1}.$$

## 2.SUPUESTO DE NORMALIDAD E INFERENCIA

- Suponíamos que  $\vec{u} \sim \mathcal{N}(\vec{0}, \sigma^2 I_n)$ .

## 2.SUPUESTO DE NORMALIDAD E INFERENCIA

- Suponíamos que  $\vec{u} \sim \mathcal{N}(\vec{0}, \sigma^2 I_n)$ .
- Como  $\vec{\tilde{\beta}} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}$ , y por T. Gauss-Markov:

$$\vec{\tilde{\beta}} \sim \mathcal{N}\left(E\left[\vec{\tilde{\beta}}\right], \text{var}\left(\vec{\tilde{\beta}}\right)\right) = \mathcal{N}\left(\vec{\beta}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

o equivalentemente:

$$\left(\vec{\tilde{\beta}} - \vec{\beta}\right) \sim \mathcal{N}\left(\vec{0}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

## 2.SUPUESTO DE NORMALIDAD E INFERENCIA

- Suponíamos que  $\vec{u} \sim \mathcal{N}(\vec{0}, \sigma^2 I_n)$ .
- Como  $\vec{\beta} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}$ , y por T. Gauss-Markov:

$$\vec{\beta} \sim \mathcal{N}\left(E\left[\vec{\beta}\right], \text{var}\left(\vec{\beta}\right)\right) = \mathcal{N}\left(\vec{\beta}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

o equivalentemente:

$$\left(\vec{\beta} - \vec{\beta}\right) \sim \mathcal{N}\left(\vec{0}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

- Como se verifica que:

$$\vec{e}^t \vec{e} = \vec{u}^t M_X \vec{u}$$

$$\vec{u} \sim \mathcal{N}\left(\vec{0}, \sigma^2 I_n\right)$$

$M_X$  es simétrica, idempotente y  $\rho(M_X) = n - k$

Concluimos que  $\frac{1}{\sigma^2} \vec{u}^t M_X \vec{u} \sim \chi_{n-k}^2$ .

## 2.SUPUESTO DE NORMALIDAD E INFERENCIA

- Suponíamos que  $\vec{u} \sim \mathcal{N}(\vec{0}, \sigma^2 I_n)$ .
- Como  $\vec{\beta} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}$ , y por T. Gauss-Markov:

$$\vec{\beta} \sim \mathcal{N}\left(E\left[\vec{\beta}\right], \text{var}\left(\vec{\beta}\right)\right) = \mathcal{N}\left(\vec{\beta}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

o equivalentemente:

$$\left(\vec{\beta} - \vec{\beta}\right) \sim \mathcal{N}\left(\vec{0}, \sigma^2 \cdot (X^t X)^{-1}\right)$$

- Como se verifica que:

$$\vec{e}^t \vec{e} = \vec{u}^t M_X \vec{u}$$

$$\vec{u} \sim \mathcal{N}\left(\vec{0}, \sigma^2 I_n\right)$$

$M_X$  es simétrica, idempotente y  $\rho(M_X) = n - k$

Concluimos que  $\frac{1}{\sigma^2} \vec{u}^t M_X \vec{u} \sim \chi_{n-k}^2 \Rightarrow \frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-k}^2$



## 2.1. INTERVALOS DE CONFIANZA

► IC para  $\beta_i$ :

$$\widehat{\beta}_i \pm t_{n-k, 1-\frac{\alpha}{2}} \cdot \sqrt{\widehat{\text{var}}[\widehat{\beta}_i]}, \quad i = 1, \dots, k.$$

siendo  $\widehat{\text{var}}[\widehat{\beta}_i]$  el elemento  $(i, i)$  de la matriz de varianzas-covarianzas estimada del estimador  $\vec{\widehat{\beta}}$ , es decir, el elemento  $(i, i)$  de  $\widehat{\text{var}}\left(\vec{\widehat{\beta}}\right)$ .

► IC para  $\sigma^2$

$$\left[ \frac{(n-k) \cdot \widehat{\sigma}^2}{\chi_{n-k, 1-\frac{\alpha}{2}}^2}, \frac{(n-k) \cdot \widehat{\sigma}^2}{\chi_{n-k, \frac{\alpha}{2}}^2} \right],$$

donde  $\chi_{n-k, 1-\frac{\alpha}{2}}^2$  y  $\chi_{n-k, \frac{\alpha}{2}}^2$  son los cuantiles de una distribución chi-cuadrado con  $n-k$  grados de libertad tal que  $P[\chi \leq \chi_{n-k, 1-\frac{\alpha}{2}}^2] = 1 - \frac{\alpha}{2}$  y  $P[\chi \leq \chi_{n-k, \frac{\alpha}{2}}^2] = \frac{\alpha}{2}$ .

## 2.2.CONTRASTE DE HIPÓTESIS

Suponiendo  $m$  restricciones lineales independientes entre sí:

$$\begin{array}{rcl} a_{11}\beta_1 + a_{12}\beta_2 + \cdots + a_{1k}\beta_k & = & r_1 \\ a_{21}\beta_1 + a_{22}\beta_2 + \cdots + a_{2k}\beta_k & = & r_2 \\ \vdots & & \vdots \\ a_{m1}\beta_1 + a_{m2}\beta_2 + \cdots + a_{mk}\beta_k & = & r_m \end{array}$$

La hipótesis nula a contrastar será:

$$H_0 : R\overrightarrow{\beta} = \overrightarrow{r}$$

donde

$$R = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1k} \\ a_{21} & a_{22} & \dots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mk} \end{pmatrix}_{m \times k}, \quad \vec{r} = \begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_m \end{pmatrix}_{m \times 1}.$$

## 2.2.CONTRASTE DE HIPÓTESIS

El estadístico de contraste asociado a la hipótesis  $H_0 : R\vec{\beta} = \vec{r}$  es

$$\begin{aligned} F_{exp} &= \frac{\left(R\vec{\beta} - \vec{r}\right)^t \cdot \left[R(X^tX)^{-1}R^t\right]^{-1} \cdot \left(R\vec{\beta} - \vec{r}\right)}{\frac{m}{\frac{\vec{e}^t\vec{e}}{n-k}}} \\ &= \left(R\vec{\beta} - \vec{r}\right)^t \cdot \frac{\left[R(X^tX)^{-1}R^t\right]^{-1}}{m\hat{\sigma}^2} \cdot \left(R\vec{\beta} - \vec{r}\right) \sim F_{m,n-k}. \end{aligned}$$

## 2.2.CONTRASTE DE HIPÓTESIS. TEST GENERAL

La hipótesis nula se rechazará si el valor del estadístico cae en la región de rechazo.

Es decir, si  $F_{exp} > F_{m,n-k,1-\alpha}$  entonces se rechaza la hipótesis  $H_0 : R\vec{\beta} = \vec{r}$ .

## 2.2.1.CASOS PARTICULARES (I): SIGNIFICACIÓN INDIVIDUAL

Si  $m = 1$  y  $r_i = 0 \forall i$ .

► **Hipótesis:**

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases}$$

► **Estadístico de contraste:**

$$t_{exp} = \left| \frac{\hat{\beta}_i}{\sqrt{\widehat{\text{var}}[\hat{\beta}_i]}} \right|$$

► **Conclusión:** Se rechaza  $H_0$  si  $t_{exp} > t_{n-k, 1-\frac{\alpha}{2}}$ .

## 2.2.1.CASOS PARTICULARES (II): ÚNICA RESTRICCIÓN LINEAL

$m = 1$  y  $r_i \neq 0 \forall i$ .

- ▶ **Hipótesis:**  $\begin{cases} H_0 : \beta_i = r_i \\ H_1 : \beta_i \neq r_i \end{cases}$
- ▶ **Estadístico de contraste:**

$$t_{exp} = \left| \frac{\hat{\beta}_i - r_i}{\sqrt{\widehat{\text{var}}[\hat{\beta}_i]}} \right|$$

- ▶ **Conclusión:** Se rechaza  $H_0$  si  $t_{exp} > t_{n-k, 1-\frac{\alpha}{2}}$ .

## 2.2.1.CASOS PARTICULARES (III): SIGNIFICACIÓN GLOBAL

Si  $m = k - 1$  y  $r_i = 0$   $i = 2, 3, \dots, k$ .

► **Hipótesis:** 
$$\begin{cases} H_0 : \beta_2 = \beta_3 = \dots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \dots, k \end{cases}$$

► **Estadístico de contraste:**

$$F_{exp} = \left( R \begin{matrix} \vec{\beta} \\ \hat{\beta} \end{matrix} \right)^t \cdot \frac{\left[ R (X^t X)^{-1} R^t \right]^{-1}}{(k - 1) \cdot \hat{\sigma}^2} \cdot \left( R \begin{matrix} \vec{\beta} \\ \hat{\beta} \end{matrix} \right)$$

► **Conclusión:** Se rechaza  $H_0$  si  $F_{exp} > F_{k-1, n-k, 1-\alpha}$ .

## 2.2.1.CONTRASTE DE SIGNIFICACIÓN GLOBAL

Teníamos:

$$\begin{cases} H_0 : \beta_2 = \beta_3 = \dots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \dots, k \end{cases}$$

Equivalentemente:

$$\begin{cases} H_0 : R \vec{\beta} = \vec{r} \\ H_1 : \text{No se verifica } H_0 \end{cases}$$

donde

$$R = \begin{pmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix}_{(k-1) \times k} \quad \vec{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix}_{k \times 1} \quad \vec{r} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}_{(k-1) \times 1}$$



## 2.2.1.CONTRASTE DE SIGNIFICACIÓN GLOBAL

Realizando la partición de las matrices:

$$X^tX = \begin{bmatrix} \mathbf{1}^t \\ X_2^t \end{bmatrix} \begin{bmatrix} \mathbf{1}^t & X_2^t \end{bmatrix} = \begin{bmatrix} n & \mathbf{1}^tX_2 \\ X_2^t\mathbf{1} & X_2^tX_2 \end{bmatrix} \quad \vec{\hat{\beta}} = \begin{bmatrix} \hat{\beta}_1 \\ \vec{\hat{\beta}}_2 \end{bmatrix}$$

## 2.2.1.CONTRASTE DE SIGNIFICACIÓN GLOBAL

Realizando la partición de las matrices:

$$X^t X = \begin{bmatrix} \mathbf{1}^t \\ X_2^t \end{bmatrix} \begin{bmatrix} \mathbf{1}^t & X_2^t \end{bmatrix} = \begin{bmatrix} n & \mathbf{1}^t X_2 \\ X_2^t \mathbf{1} & X_2^t X_2 \end{bmatrix} \quad \vec{\hat{\beta}} = \begin{bmatrix} \hat{\beta}_1 \\ \vec{\hat{\beta}}_2 \end{bmatrix}$$

$$\frac{\left( \vec{R\hat{\beta}} - \vec{r} \right)^t \cdot \left[ R(X^t X)^{-1} R^t \right]^{-1} \cdot \left( \vec{R\hat{\beta}} - \vec{r} \right)}{\frac{m}{\frac{\vec{e}^t \vec{e}}{n-k}}}$$

## 2.2.1.CONTRASTE DE SIGNIFICACIÓN GLOBAL

Realizando la partición de las matrices:

$$X^t X = \begin{bmatrix} \mathbf{1}^t \\ X_2^t \end{bmatrix} \begin{bmatrix} \mathbf{1}^t & X_2^t \end{bmatrix} = \begin{bmatrix} n & \mathbf{1}^t X_2 \\ X_2^t \mathbf{1} & X_2^t X_2 \end{bmatrix} \quad \vec{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \vec{\beta}_2 \end{bmatrix}$$

$$\frac{\left( \vec{R} \vec{\beta} - \vec{r} \right)^t \cdot \left[ R (X^t X)^{-1} R^t \right]^{-1} \cdot \left( \vec{R} \vec{\beta} - \vec{r} \right)}{\frac{m}{\frac{\vec{e}^t \vec{e}}{n-k}}}$$

$$\frac{\vec{\beta}_2^t \cdot \left[ X_2^t X_2 - X_2^t \mathbf{1}_n \mathbf{1}^t X_2 \right]^{-1} \cdot \vec{\beta}_2}{\frac{\vec{e}^t \vec{e}}{n-k}} = \frac{\vec{\beta}_2^t X_2^t A X_2 \vec{\beta}_2}{\frac{\vec{e}^t \vec{e}}{n-k}} \sim F_{k-1, n-k}$$

donde  $A = I_n - \frac{1}{n} \mathbf{1} \cdot \mathbf{1}^t$ .

## 2.2.1.ANOVA

Considerando que se verifica

$$\begin{array}{rcl} \vec{y}^t A \vec{y} & = & \vec{\beta}_2^t X_2^t A X_2 \vec{\beta}_2 + \vec{e}^t \vec{e} \\ (SCT) & = & (SCE) + (SCR) \end{array}$$

El estadístico experimental se puede escribir como:

$$F_{exp} = \frac{\frac{1}{k-1} SCE}{\frac{1}{n-k} SCR}$$

## 2.2.1.ANOVA

ANOVA El **Análisis de la Varianza** es el contraste que estudia la significación global del modelo donde:

- Hipótesis  $\begin{cases} H_0 : \beta_2 = \beta_3 = \dots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \dots, k \end{cases}$
- Estadístico de contraste

$$F_{exp} = \frac{\frac{1}{k-1} SCE}{\frac{1}{n-k} SCR}$$

- Conclusión Se rechaza  $H_0$  si  $F_{exp} > F_{k-1, n-k, 1-\alpha}$ .

## TABLA ANOVA

Fuente de variación	Suma de Cuadrados	Grados de Libertad	Medias
Explicada	$SCE = \vec{\beta}^t X^t \vec{y} - n \bar{Y}^2$	$k - 1$	$\frac{SCE}{k-1}$
Residuos	$SCR = \vec{y}^t \vec{y} - \vec{\beta}^t X^t \vec{y}$	$n - k$	$\frac{SCR}{n-k}$
Total	$SCT = \vec{y}^t \vec{y} - n \bar{Y}^2$	$n - 1$	

Como

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

$$F_{exp} = \frac{\frac{1}{k-1} SCE}{\frac{1}{n-k} SCT(1 - R^2)} = \frac{\frac{1}{k-1} R^2}{\frac{1}{n-k} (1 - R^2)} = \frac{n - k}{k - 1} \frac{R^2}{(1 - R^2)}$$

## COTA $R^2$

Se rechaza  $H_0$  cuando  $F_{exp} > F_{k-1, n-k, 1-\alpha}$ , esto es si

$$\frac{n-k}{k-1} \frac{R^2}{(1-R^2)} > F_{k-1, n-k, 1-\alpha} \Rightarrow R^2 > \frac{(k-1) \cdot F_{k-1, n-k, 1-\alpha}}{(n-k) + (k-1) \cdot F_{k-1, n-k, 1-\alpha}}.$$

### 3.PREDICCIÓN PUNTUAL

Una vez estimado y validado el modelo  $Y = \vec{\beta} X + u_t$ :

- ▶ Si tenemos nuevos datos  $\vec{x}_0^t = (1 \ X_{20} \ X_{30} \ \dots \ X_{k0})$ ,
- ▶ Suponiendo que tenemos **permanencia estructural en la especificación del modelo** (el proceso de generación de los datos para la nueva observación  $\vec{x}_0$  es el mismo que ha generado la información muestral)
- ▶ Podemos tomar como **predictor para el valor medio y para el valor individual de la variable endógena**

$$\vec{x}_0^t \vec{\beta} = \hat{y}_0 = E[\widehat{y_0} | \vec{x}_0]$$

(el predictor mínimo cuadrático  $\hat{y}_0$  es lineal, insesgado y óptimo)

#### Nota 1

*Adviértase que, aunque se obtiene el mismo predictor para el valor individual  $y_0$  como para  $E[\widehat{y_0} | \vec{x}_0]$ , los errores de predicción obtenidos con ambas variables no coinciden entre sí, y por consiguiente las varianzas asociadas a dichos errores también serán distintas.*



### 3.PREDICCIÓN PUNTUAL PARA EL VALOR INDIVIDUAL

Considerando el valor individual  $y_0 = \vec{x}_0^t \vec{\beta} + u_0$  se tiene que el error de predicción corresponde:

$$e_0 = y_0 - \hat{y}_0 = \vec{x}_0^t \vec{\beta} + u_0 - \vec{x}_0^t \vec{\tilde{\beta}} = u_0 - \vec{x}_0^t (\vec{\tilde{\beta}} - \vec{\beta}) \sim \mathcal{N}(E[e_0], \text{var}[e_0])$$

$$E[e_0] = E[u_0 - \vec{x}_0^t (\vec{\tilde{\beta}} - \vec{\beta})] = \vec{x}_0^t (E[\vec{\tilde{\beta}}] - \vec{\beta}) = 0.$$

### 3.PREDICCIÓN PUNTUAL PARA EL VALOR INDIVIDUAL

$$\begin{aligned}
 \text{var}[e_0] &= \text{var}[u_0 - \vec{x}_0^t(\vec{\beta} - \vec{\beta})] = \text{var}(u_0) + \text{var}(\vec{x}_0^t(\vec{\beta} - \vec{\beta})) - 2\text{cov}(u_0 \vec{x}_0^t(\vec{\beta} - \vec{\beta})) \\
 &= \text{var}(u_0) + \text{var}(\vec{x}_0^t(\vec{\beta} - \vec{\beta})) - 2\text{cov}(u_0 \vec{x}_0^t(X^t X)^{-1} X^t \vec{u}) = {}^1 = \\
 &= \text{var}(u_0) + \text{var}(\vec{x}_0^t(\vec{\beta} - \vec{\beta})) = \sigma^2 + E[\vec{x}_0^t(\vec{\beta} - \vec{\beta})(\vec{\beta} - \vec{\beta})^t \vec{x}_0] = \\
 &= \sigma^2 + \vec{x}_0^t E[(\vec{\beta} - \vec{\beta})(\vec{\beta} - \vec{\beta})^t] \vec{x}_0 = \sigma^2 + \vec{x}_0^t \sigma^2 (X^t X)^{-1} \vec{x}_0 = \\
 &=
 \end{aligned}$$

$$e_0 \sim N(0, \sigma^2(1 + \vec{x}_0^t (X^t X)^{-1} \vec{x}_0))$$

---

<sup>1</sup>  $\text{cov}(u_0 \vec{x}_0^t(\vec{\beta} - \vec{\beta})) = 0$  al no existir correlación entre  $u_0$  y  $\vec{u}$ .

<sup>1</sup>  $\text{cov}(u_0 \vec{x}_0^t(\vec{\beta} - \vec{\beta})) = 0$  al no existir correlación entre  $u_0$  y  $\vec{u}$ .

### 3.PREDICCIÓN PUNTUAL PARA EL VALOR ESPERADO

$E[y_0 | \vec{x}_0]$  tiene como residuo:

$$e_0^* = E[y_0 | \vec{x}_0] - \widehat{E[y_0 | \vec{x}_0]} = \vec{x}_0^t \vec{\beta} - \vec{x}_0^t \vec{\hat{\beta}} = -\vec{x}_0^t (\vec{\hat{\beta}} - \vec{\beta}) \sim \mathcal{N}(E[e_0^*], \text{var}[e_0^*])$$

$$E[e_0^*] = E[-\vec{x}_0^t (\vec{\hat{\beta}} - \vec{\beta})] = \vec{x}_0^t (E[\vec{\hat{\beta}}] - \vec{\beta}) = 0.$$

$$\begin{aligned} \text{var}[e_0^*] &= \text{var}[-\vec{x}_0^t (\vec{\hat{\beta}} - \vec{\beta})] = \vec{x}_0^t \text{var}(\vec{\hat{\beta}} - \vec{\beta}) \vec{x}_0 = \\ &= \vec{x}_0^t \text{var}(\vec{\hat{\beta}}) \vec{x}_0 = \vec{x}_0^t \sigma^2 (X^t X)^{-1} \vec{x}_0 = \\ &= \sigma^2 \vec{x}_0^t (X^t X)^{-1} \vec{x}_0. \end{aligned}$$

$$e_0^* = E[y_0 | \vec{x}_0] - \widehat{E[y_0 | \vec{x}_0]} \sim N(0, \sigma^2 \vec{x}_0^t (X^t X)^{-1} \vec{x}_0)$$

### 3.PREDICCIÓN POR INTERVALO

En las distirbuciones de  $e_0$  y  $e_0^*$ ,  $\sigma^2$  es desconocida. Teniendo en cuenta que

$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-k}^2,$$

$$\frac{\frac{\hat{y}_0 - \vec{x}_0^t \vec{\beta}}{\sqrt{\sigma^2(1 + \vec{x}_0^t (X^t X)^{-1} \vec{x}_0)}}}{\sqrt{\frac{\frac{(n-k)\hat{\sigma}^2}{\sigma^2}}{n-k}}} = \frac{\hat{y}_0 - \vec{x}_0^t \vec{\beta}}{\hat{\sigma} \sqrt{1 + \vec{x}_0^t (X^t X)^{-1} \vec{x}_0}} \sim t_{n-k}$$

$$\frac{\frac{E[\widehat{y_0 | \vec{x}_0}] - \vec{x}_0^t \vec{\beta}}{\sqrt{\sigma^2(\vec{x}_0^t (X^t X)^{-1} \vec{x}_0)}}}{\sqrt{\frac{\frac{(n-k)\hat{\sigma}^2}{\sigma^2}}{n-k}}} = \frac{E[\widehat{y_0 | \vec{x}_0}] - \vec{x}_0^t \vec{\beta}}{\hat{\sigma} \sqrt{\vec{x}_0^t (X^t X)^{-1} \vec{x}_0}} \sim t_{n-k}$$

### 3.PREDICCIÓN POR INTERVALO

- Intervalo de confianza para el valor individual  $y_0$ .

$$\begin{aligned} IC_{y_0} &= \hat{y}_0 \pm t_{n-k, 1-\frac{\alpha}{2}} \cdot \hat{\sigma} \sqrt{1 + \vec{x}_0^t (X^t X)^{-1} \vec{x}_0} \\ &= \vec{x}_0^t \vec{\hat{\beta}} \pm t_{n-k, 1-\frac{\alpha}{2}} \cdot \hat{\sigma} \sqrt{1 + \vec{x}_0^t (X^t X)^{-1} \vec{x}_0} \end{aligned}$$

- Intervalo de confianza para  $E[y_0 | \vec{x}_0]$ .

$$\begin{aligned} IC_{E[y_0 | \vec{x}_0]} &= E[\widehat{y_0 | \vec{x}_0}] \pm t_{n-k, 1-\frac{\alpha}{2}} \cdot \hat{\sigma} \sqrt{\vec{x}_0^t (X^t X)^{-1} \vec{x}_0} \\ &= \vec{x}_0^t \vec{\hat{\beta}} \pm t_{n-k, 1-\frac{\alpha}{2}} \cdot \hat{\sigma} \sqrt{\vec{x}_0^t (X^t X)^{-1} \vec{x}_0} \end{aligned}$$

## DISTRIBUCIONES $\chi^2$ Y $t$ -STUDENT

- La distribución  $\chi^2$  de Pearson con  $n$  grados de libertad,  $\chi_n^2$ , se construye como la suma de los cuadrados de  $n$  variables aleatorias independientes e idénticamente distribuidas según una  $\mathcal{N}(0, 1)$ :

$$\chi_n^2 = \sum_{i=1}^n X_i^2, \quad X_i \sim N(0, 1), \quad \forall i.$$

- La distribución  $t$ -Student con  $n$  grados de libertad,  $t_n$ , se construye como el cociente entre una variable aleatoria  $\mathcal{N}(0, 1)$  y la raíz cuadrada de una  $\chi^2$ -cuadrado de  $n$  grados de libertad dividida entre sus grados de libertad, siendo ambas distribuciones independientes:

$$t_n = \frac{X}{\sqrt{\frac{Y}{n}}}, \quad X \sim N(0, 1), \quad Y \sim \chi_n^2.$$

### Propiedades:

- $\chi^2$  NO es simétrica,  $t$ -Student SÍ es simétrica.
- Para  $n > 30$ , la distribución  $t$ -Student se puede aproximar a una distribución Normal.

# DISTRIBUCIÓN $F$ -SNEDECOR

- ▶ La distribución  $F$  de Snedecor con  $n$  y  $m$  grados de libertad, que denotaremos por  $F_{n,m}$ , se construye a partir del cociente de dos variables aleatorias independientes y distribuidas según chi-cuadrados con  $n$  y  $m$  grados de libertad, respectivamente, divididas entre sus correspondientes grados de libertad. Por tanto, la distribución  $F$  de Snedecor responde a la siguiente estructura:

$$F_{n,m} = \frac{\frac{X}{n}}{\frac{Y}{m}}, X \sim \chi_n^2, Y \sim \chi_m^2.$$

## Propiedades:

- ▶ La distribución  $F_{n,m}$  NO es simétrica.
- ▶  $F_{m,n,1-\alpha} = \frac{1}{F_{n,m,\alpha}}$ .
- ▶  $t_n^2 = F_{1,n}$ .

# NOTACIÓN MATRICIAL

Se define la matriz  $A$  como

$$\begin{aligned} A &= \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix} - \frac{1}{n} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} (1 \quad 1 \quad \dots \quad 1) \\ &= \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix} - \frac{1}{n} \begin{pmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{pmatrix} \end{aligned}$$

## Propiedades:

- ▶ La matriz  $A$  es simétrica e idempotente.
- ▶  $A(1, \dots, 1)^t = \vec{0}$  y  $A\vec{e} = \vec{e}$ .
- ▶  $A\vec{y}$  es:

$$A\vec{y} = \begin{pmatrix} Y_1 - \bar{Y} \\ Y_2 - \bar{Y} \\ \vdots \\ Y_n - \bar{Y} \end{pmatrix}$$